

한국어-영어 번역을 위한 **Transformer** 모델 개발

한국어와 영어 간 기계 번역을 위한
Transformer 모델 구축 프로젝트 소개

정교한 데이터 정제와 **SentencePiece** 토큰나이저를 통한 학습 환경 구축

STEP 01

데이터 정제

중복 제거 및 정규식
노이즈 제거



STEP 02

토큰화 수행

SentencePiece
Vocab 20,000 설정



STEP 03

패딩 및 제한

최대 문장 길이 설정
및 패딩 완료


VOCABULARY SIZE

20,000

효과적인 기계 번역을 위해 중복 데이터 및 정규식을 활용한 노이즈 제거 등 철저한 데이터 정제 과정을 수행했습니다. 이후 **SentencePiece** 토큰나이저를 적용하여 단어 사전 크기를 20,000개로 설정하고 학습을 진행했습니다.

토큰화 결과와 데이터 분포 분석을 바탕으로 모델 입력에 적합한 최대 문장 길이를 설정하고, 길이를 맞추기 위한 패딩(Padding) 처리를 완료하여 안정적인 학습 환경을 구축했습니다.

TEXT PROCESSING SCHEMATIC: TOKENIZATION



SCHEMATIC SYSTEM


Tokenization Process

SentencePiece를 활용하여 별도의 형태소 분석기 없이 한국어와 영어의 서브워드 토큰화를 통합 수행합니다.

Multi-Head Attention 기반

모델 구조 및 하이퍼파라미터 최적화

MODEL ARCHITECTURE FLOW



OPTIMIZATION SETTINGS

본 프로젝트는 **Multi-Head Attention**과 **Positional Encoding**을 포함한 핵심 트랜스포머 (Transformer) 구조를 성공적으로 구현했습니다.

또한, 학습 안정성과 수렴 속도를 높이기 위해 맞춤형 **학습 스케줄러 (Learning Rate Scheduler)**를 적용하여 최적화 과정을 진행했습니다.

```
# Model Hyperparameters
d_model = 512
num_heads = 8
d_ff = 2048
num_layers = 6
```

학습 결과 시각화 & BLEU 성능 평가


BLEU SCORE (EN-KO)

24.5

학습 과정에서 기록된 Loss 감소 및 Accuracy 변화 추이를 시각화하여 모델의 안정적인 수렴을 확인했습니다.

번역 결과 생성 과정을 분석하고, 객관적인 영-한 번역 성능 지표인 BLEU 점수를 통해 모델의 유효성을 평가했습니다.

TRAINING LOSS & ACCURACY TRENDS



한계점 및 향후 개선 방향 (LIMITATIONS & FUTURE WORK)

현재 모델의 복잡한 문맥 파악 한계점을 극복하기 위해, 향후 더 큰 규모의 코퍼스 적용 및 하이퍼파라미터 미세 조정 (Fine-tuning)을 통해 성능 개선을 추진합니다.

KoChatGPT 정렬을 위한 3단계 RLHF 강화학습 파이프라인

STEP 01

지도 미세조정 (SFT)

선별된 한국어 지시어-답변 쌍 (Instruction-Response Pairs)을 활용하여 기초 KoGPT 모델의 가중치를 미세조정합니다.

- 대화형 비서로서의 기본 모델 구축
- 유저의 지시 문맥 이해도 극대화

STEP 02

보상 모델링 (RM)

모델이 생성한 여러 답변 아웃풋의 순위를 매겨, 인간의 선호도(유용성, 유창성, 안전성)를 학습하는 분류기 (Preference Classifier)를 훈련합니다.

- 인간 피드백 데이터의 정량화
- 유해 답변 필터링 및 정렬 기준 수립

STEP 03

PPO 강화학습 (RLHF)

수립된 보상 모델을 기준으로 SFT 정책 네트워크를 PPO 알고리즘을 통해 최적화하며, KL-divergence 패널티를 부여해 급격한 정책 변동을 방지합니다.

- 최종 일관성 및 생성 안정성 확보
- 안전한 한국어 생성 성능 극대화