



KoChatGPT 성능 향상 및 최적화 절제 연구 (Ablation Study)

데이터 품질, 학습 기법, 모델 스케일이 한국어 LLM 성능과 경제성에 미치는 영향

발표자: GiHoon Jang

학계 및 연구원을 대상으로 한 프로젝트 최종 보고서 개요

sLLM Ablation Study



Research Purpose & Background

KoGPT2 기반 초소형 LLM의 효율적 튜닝 기법 분석

본 프로젝트는 초기 한국어 언어모델인 KoGPT2(125M 파라미터)를 베이스라인으로 설정하여, 최신 대형 언어 모델(LLM) 튜닝 기법들을 적용하고 그 효과를 정량적, 정성적으로 분석하는 데 목적이 있습니다.

특히 한정된 컴퓨팅 자원 내에서 생성 품질과 서비스 경제성을 극대화하기 위해 세 가지 핵심 질문을 설정하고 단계별 절제 연구(Ablation Study)를 수행했습니다.

→ 이를 통해 학계 및 연구원들에게 효율적인 sLLM(소형 대형 언어 모델) 구축을 위한 실증적 데이터를 제공하고자 합니다.

3 Core Ablation Questions

01 데이터 정제를 통한 한계 극복

고품질 데이터 정제 작업이 모델의 파라미터 수 부족이라는 태생적 한계를 극복할 수 있는가?

02 PPO의 실질적 대안 검증

연산량이 많고 학습이 불안정한 PPO(Proximal Policy Optimization) 방식 대신, 보상 모델(Reward Model)을 활용한 간소화된 Best-of-N Re-ranking 기법이 실질적인 대안이 될 수 있는가?

03 품질과 비용의 최적 타협점

파라미터 규모를 1.2B로 확장(Scale-up)하는 동시에 LoRA(Low-Rank Adaptation) 튜닝을 적용하는 것이 품질 향상과 비용 절감 사이의 최적의 타협점인가?



"Garbage In, Garbage Out"

기계학습의 오랜 격언은 LLM 파인튜닝 단계에서도 예외 없이, 더욱 엄격하게 적용됩니다.

- **철저한 노이즈 데이터 정제:** 불필요한 따옴표, 문맥에 맞지 않는 영어 혼입, 무의미한 회피성 응답 등 데이터셋 내에 존재하는 미세한 노이즈를 완전하게 제거하는 파이프라인을 구축하여 고밀도 지식 학습의 기초를 설계하였습니다.
- **한국어 지시 이행력 극대화:** 고품질 정제 데이터로 학습한 모델은 기존의 베이스라인 모델 대비 지시 수행 및 정렬 성능이 비약적으로 향상되었습니다. 특히 다중 턴 대화 및 복잡한 지시 맥락에서의 실행 능력이 뚜렷한 상승세를 기록했습니다.
- **환각 방지 및 리소스 효율성:** 정밀하게 정제된 데이터셋은 환각(Hallucination) 현상을 극적으로 억제하고 출력 서식 오류를 사전에 차단하였습니다. 이는 파라미터 크기 증가나 무리한 추가 컴퓨팅 연산 투입 대비 최고 수준의 비용 대비 효율성을 입증합니다.

정렬 기법 가성비 분석: PPO vs Best-of-N



인간의 선호도를 모델에 정렬(Alignment)하는 기법의 리소스 대비 성능 효율성을 비교 분석합니다. 복잡하고 무거운 PPO 강화학습을 거치지 않더라도, 잘 학습된 보상 모델(RM)을 활용한 생성물 재정렬만으로 유의미한 응답 품질 개선을 달성할 수 있습니다.

PPO 기반 풀 정렬 (RLHF)

- **학습 과정의 극심한 불안정성**
강화학습 특유의 불안정한 수렴 성능 및 복잡한 초매개변수 (Hyperparameter) 튜닝 요구
- **막대한 연산 및 자원 소모**
액터-크리틱 구조 유지로 인한 대규모 GPU 메모리 점유 및 연산 하드웨어 부하 가중
- **복잡한 다단계 파이프라인**
데이터 수집, 보상 모델링, 온라인 RL 피드백 루프를 모두 관장하는 높은 인프라 장벽

VS

Best-of-N Re-ranking

- **고효율 가성비 정렬 메커니즘**
추가적인 정책 모델 파라미터 업데이트 없이, SFT 단독 모델에 보상 모델 (RM)을 결합
- **정량적 지표의 유의미한 상승**
SFT 단독 대비 BLEU, ROUGE 등 주요 자동 평가 메트릭에서 확실한 동반 향상 달성
- **정성적 응답 품질 대폭 개선**
생성 결과물 필터링 및 재정렬만으로 문맥 적합성, 유창성 등 실제 인간의 선호도 모사



1.2B

PARAMETER SCALE-UP EFFECT

지식의 깊이와 복잡한 문맥 유지 능력 향상

- 모델 규모를 125M에서 **1.2B 파라미터로 확장**함에 따라 내재된 기본 지식의 총량과 문맥 이해 능력이 비약적으로 상승했습니다.
- 이러한 대규모 스케일업은 기존의 데이터 정제나 학습 기법 변경을 뛰어넘어, 생성 품질 면에서 **가장 결정적이고 근본적인 차이**를 만듭니다.

LoRA

PEFT ECONOMICS & EFFICIENCY

Full SFT 대비 극적인 컴퓨팅 비용 절감

- 1.2B 규모를 Full SFT로 튜닝하는 막대한 비용을 극복하기 위해 가중치 행렬을 저랭크로 분해하여 학습하는 **LoRA 기법을 도입**했습니다.
- 적용 결과 **GPU VRAM 사용량을 대폭 절감**하면서도 성능 하락은 통계적으로 미미했으며, **Google Colab T4(단일 GPU)** 환경에서도 파인튜닝을 원활하게 실증했습니다.

LATENCY VS. QUALITY TRADE-OFF



모델 크기별 지연 시간(Latency)과 생성 품질(Quality) 간의 Trade-off를 종합적으로 비교 분석한 결과입니다.

KoGPT2 (125M)

- 추론 속도가 매우 빠르고 VRAM 점유율이 극히 낮음 (최저 리소스 강점)
- 복잡한 추론 능력은 제한적이나 실시간 초고속 응답 환경에 필수적
- **적합 서비스:** 저사양 엣지 디바이스, 단순 챗봇, 기본 감성 분석, 단답형 질의응답

VS

Trinity (1.2B)


- 생성 품질, 문맥 유지 능력, 논리적 추론 측면에서 매우 우수한 성능 보장
- 텍스트 생성 지연(Latency)이 길어지고 런타임 VRAM 요구량(부하)이 큼
- **적합 서비스:** 전문 지식 QA, 긴 문서 요약, 복잡한 다단계 추론, 엔터프라이즈 AI

Service Planner Insight

서비스 기획자는 요구되는 응답 속도와 작업의 복잡도를 고려하여 적합한 스케일의 모델을 선택해야 합니다.

CONCLUSION: THE OPTIMAL sLLM EQUATION

결론: 독자적 sLLM 서비스 구축을 위한 최적 방정식



천문학적 비용이 드는 거대 상용 모델(ChatGPT, GPT-4 등)의 API에 전적으로 의존하지 않고도, 특정 도메인에 특화되고 경제적인 성능을 발휘하는 자체 AI 서비스를 구현할 수 있는 성공 공식을 확인했습니다.

01. 정밀 데이터 정제

도메인 특성이 반영된 "정밀하게 정제된 대규모 데이터" 확보가 가장 기초가 되어야 합니다. 고품질 데이터의 정밀화가 결국 AI 모델 전체의 실용적이고 안정적인 성능을 좌우하게 됩니다.

02. Best-of-N RM 정렬

값비싼 PPO 대신 "보상 모델(RM)을 활용한 인간 선호도 정렬(Best-of-N)"을 통해 응답 품질을 효율적으로 최적화합니다. 제한적인 연산 예산 내에서도 뛰어난 정렬 성능을 도출하는 핵심 요소입니다.

03. 1.2B Base & LoRA

타겟 서비스의 복잡도와 자원 제약을 고려하여 "적정 크기의 베이스 모델(예: 1.2B)을 선정하고 PEFT(LoRA) 튜닝"을 적용합니다. 이를 통해 학습 부담과 실시간 서빙 지연 비용을 혁신적으로 절감합니다.