

DKTC 대화 유형 분류 모델

KLUE-RoBERTa 파인튜닝 결과 발표 대본

본 대본은 협박 / 갈취 / 직장 내 괴롭힘 / 기타 괴롭힘 / 일반 대화의 5개 클래스를 분류하는 KLUE-RoBERTa 기반 모델의 검증 결과를 발표하기 위한 스크립트입니다. 각 섹션은 <예상 소요 시간>, <화면에 보여줄 내용>, <말할 대본> 순서로 구성되어 있습니다.

1. 오프닝 — 발표 개요

예상 소요 시간: 약 30초

[화면] 타이틀 슬라이드 (모델명: KLUE-RoBERTa Baseline, 데이터셋: DKTC)

안녕하십니까. 지금부터 한국어 위협 대화 데이터셋, DKTC를 활용한 대화 유형 분류 모델의 학습 및 평가 결과를 발표하겠습니다.

오늘 발표는 klue/roberta-base 모델을 파인튜닝하여 협박, 갈취, 직장 내 괴롭힘, 기타 괴롭힘, 그리고 일반 대화까지 총 5개 클래스를 분류한 실험 결과를 중심으로 진행됩니다.

먼저 전체 성능 지표를 말씀드린 뒤, 클래스별 세부 결과와 오분류 패턴을 분석하고, 마지막으로 개선 방향을 제안하는 순서로 말씀드리겠습니다.

2. 전체 성능 지표

예상 소요 시간: 약 1분

[화면] Val Macro F1 / Val Accuracy 지표 표

지표	값
Val Macro F1	0.9211
Val Accuracy	0.9276

저희 모델은 검증 데이터에서 Macro F1 0.9211, Accuracy 0.9276을 기록했습니다. Macro F1과 Accuracy가 큰 차이 없이 모두 92%대로 나타났다는 점은, 특정 다수 클래스에 치우치지 않고 5개 클래스 전반에 걸쳐 고르게 잘 분류하고 있다는 의미로 해석할 수 있습니다.

특히 클래스 불균형이 있는 분류 문제에서는 Accuracy만으로 성능을 판단하면 다수 클래스에 유리하게 왜곡될 수 있는데, 두 지표가 근접하다는 것은 모델이 소수 클래스에서도 안정적인 성능을 보이고 있다는 신뢰할 만한 근거가 됩니다.

3. 클래스별 분류 리포트

예상 소요 시간: 약 2분

[화면] 클래스별 Precision / Recall / F1-Score 표

클래스	Precision	Recall	F1-Score
협박 (0)	0.89	0.93	0.91
갈취 (1)	0.92	0.87	0.89
직장 내 괴롭힘 (2)	0.95	0.94	0.95
기타 괴롭힘 (3)	0.92	0.87	0.90
일반 (4)	0.95	1.00	0.97
Macro Avg	0.92	0.92	0.92
Weighted Avg	0.93	0.93	0.93

클래스별로 살펴보면, '일반' 클래스는 Recall 1.00, F1 0.97로 가장 뛰어난 성능을 보였습니다. 이는 일반 대화가 위협·괴롭힘 표현이 담긴 다른 4개 클래스와 어휘적, 맥락적으로 뚜렷하게 구분되기 때문으로 해석됩니다.

'직장 내 괴롭힘' 클래스 역시 Precision 0.95, Recall 0.94로 우수한 성능을 보였는데, 직장이라는 특정 맥락과 어휘가 뚜렷해 다른 클래스와 잘 구분된 것으로 보입니다.

반면 '갈취'와 '기타 괴롭힘'은 Recall이 각각 0.87로 상대적으로 낮았습니다. 즉, 실제로는 갈취나 기타 괴롭힘 대화인데 모델이 다른 클래스로 잘못 예측한 사례가 상대적으로 많았다는 의미이며, 이는 다음 오류 분석에서 자세히 다루겠습니다.

4. 주요 오분류 패턴 (오류 분석)

예상 소요 시간: 약 2분

[화면] Confusion Matrix 및 Top-3 오분류 패턴 표

전체 787건의 검증 샘플 중 오분류는 57건으로, 오분류율은 7.2% 수준입니다.

실제 → 예측	건수
갈취 → 협박	13건
기타 괴롭힘 → 갈취	12건
협박 → 갈취	6건

가장 두드러지는 패턴은 '갈취'를 '협박'으로 잘못 예측한 13건입니다. 두 클래스 모두 상대를 위협하는 언어 표현을 공유하고 있어, 금품이나 이익을 요구하는 명시적 문맥이 짧거나 암시적인 경우 모델이 협박과 혼동하는 것으로 보입니다.

두 번째로 '기타 괴롭힘'을 '갈취'로 예측한 12건이 있었습니다. 이는 '기타 괴롭힘' 클래스 자체가 다른 4개 클래스에 속하지 않는 다양한 형태의 괴롭힘을 포괄하는 범주이다 보니, 경계가 상대적으로 모호해 발생하는 오류로 판단됩니다.

마지막으로 '협박'을 '갈취'로 예측한 6건도 확인되는데, 이는 첫 번째 패턴과 대칭적인 혼동으로, 협박과 갈취 두 클래스 사이의 경계 자체가 근본적으로 모호하다는 것을 다시 한번 보여줍니다.

종합하면, 본 모델의 주요 과제는 크게 두 가지입니다. 첫째, '협박'과 '갈취' 간의 의미적 경계를 더 명확히 학습시키는 것. 둘째, '기타 괴롭힘' 클래스의 모호성을 완화하는 것입니다.

5. 클로징 — 요약 및 개선 방향 제안

예상 소요 시간: 약 1분

[화면] 요약 슬라이드 (핵심 수치 + 개선 방향 bullet)

정리하겠습니다. 저희 KLUE-RoBERTa 기반 모델은 검증 데이터에서 Macro F1 0.9211, Accuracy 0.9276을 달성했으며, 5개 클래스 전반에 걸쳐 균형 잡힌 성능을 보였습니다.

다만 '갈취'와 '협박' 간의 혼동, 그리고 '기타 괴롭힘' 클래스의 경계 모호성이 주요 개선 과제로 확인되었습니다.

향후에는 이 세 클래스 쌍에 해당하는 오분류 샘플을 집중적으로 재검토하고, 해당 경계 사례를 보강하는 데이터 증강이나 클래스 정의 재정비를 통해 성능을 추가로 끌어올릴 수 있을 것으로 기대합니다.

이상으로 발표를 마치겠습니다. 감사합니다.

※ 본 대본의 시간 배분은 예시이며, 실제 발표 시간(질의응답 포함 여부 등)에 맞춰 조정하시기 바랍니다.